



Université de
Sherbrooke

Université de Sherbrooke

Données manquantes

Fondements

TMR_07

Christina KHNAISSER (christina.khnaisser@usherbrooke.ca)

Luc LAVOIE (luc.lavoie@usherbrooke.ca)

(les auteurs sont cités en ordre alphabétique nominal)

Scriptorum/Scriptorum/TMR_07-Donnees_manquantes, version 0.1.2.a, en date du 2025-09-02

— document de travail, ne pas citer —

Plan

Introduction	3
1. Présentation	4
Conclusion	12
Références.	13

Introduction

Le présent document a pour but de présenter une synthèse du problème posé par la modélisation des données manquantes et de diverses solutions proposées par Edgar F. Codd et développée grâce, notamment, aux contributions de Christopher J. Date, Hugh Darwen, Nikos A. Lorentzos et Jeffrey D. Ullman.

1. Présentation

1.1. Définitions

1.1.1. Définition SPARC

Les données manquantes selon SPARC

1. L'information est applicable, mais la valeur n'est pas encore connue (ex. date de décès d'une personne vivante).
2. L'information est inapplicable (ex. nombre de sommets d'un cercle).
3. L'information existe, mais il n'est pas permis (légalement) de l'enregistrer (ex. religion d'un employé).
4. L'information existe, mais on n'a pas les moyens de trouver la valeur (ex. évaluation d'un employé alors qu'il travaillait pour une organisation

concurrente).

5. L'information existe, mais elle n'est pas encore enregistrée (ex. en raison de l'absence du préposé à la saisie).
6. L'information est enregistrée, mais pas encore disponible (ex. texte écrit, saisi, stocké, mais pas encore publié).
7. L'information a été enregistrée puis supprimée (ex. un utilisateur ne veut plus que le nom de son conjoint soit conservé).
8. L'information est disponible, mais en changement et donc potentiellement invalide (ex. solde d'un compte bancaire sur lequel une opération est en cours).
9. L'information est disponible, mais on ne sait pas si elle est fiable (ex. la note finale d'une activité non encore approuvée par la directrice du département).
10. L'information est disponible, mais invalide (ex. si une erreur s'est produite lors du calcul de la valeur).

11. La classe d'information est sécurisée (ex. les informations personnelles des professeurs ne sont pas accessibles aux étudiants).
12. L'objet représentant l'information est sécurisé (ex. un utilisateur bloque l'accès à ses infos personnelles sur un réseau social).
13. Une information est sécurisée durant un certain laps de temps (ex. le budget préalablement à sa communication au parlement).
14. L'information est calculée à partir d'au moins une information manquante ou incertaine (ex. l'âge en fonction d'une date de naissance par ailleurs manquante).

1.1.2. Définition Codd

Les données manquantes selon Codd :

1. L'information n'est pas applicable : dans ce cas, l'utilisation de l'annulabilité est à remettre en question; une bonne modélisation permet généralement d'éviter d'y avoir recours.
2. L'information est inconnue : dans ce cas, l'annulabilité pourrait être légitime; la question est de savoir comment la représenter pour que cela pose le moins de problèmes possible.
3. L'information n'est pas accessible : dans ce cas, le gestionnaire transactionnel permet d'éviter l'utilisation de l'annulabilité en différant la mise à disponibilité tout en conservant le contrôle des accès concurrents et en préservant la cohérence de la BD.

1.2. Solutions

Que faire lorsqu'une donnée est manquante?

Trois solutions classiques :

1. corriger cette lacune à la source (dans la réalité, avant la collecte);
2. modifier le modèle pour en tenir compte;
3. introduire la notion d'annulabilité dans la théorie relationnelle.

1.2.1. Solutions sans annulabilité

Avantage

Conserver la théorie relationnelle telle quelle.

Conséquences

- Séparer les propositions complètes des incomplètes (par modélisation).
- Conserver les causes de manque séparément (par modélisation).

1.2.2. Solutions avec annulabilité

Avantage

Réduire la complexité des modèles de données (mais pas forcément celle des assertions sur ces modèles).

Conséquences

- Remplacement au sein de la théorie relationnelle de la logique classique par une logique non classique.
 - Impact sur l'égalité, essentielle à la définition des opérateurs d'affectation, de restriction, de jointure, d'union...
 - Impact sur l'inférence logique (et en particulier la déduction) qui est nécessaire à la démonstration de l'exactitude des requêtes.
- Modification du modèle relationnel pour y introduire la dénotation du manque, grâce à l'un des deux artifices suivants :

- un marqueur NUL (une propriété des attributs) ou
- une valeur NULLE (ajoutée à tous les domaines).

Conclusion

Il n'y a pas consensus sur la bonne façon de traiter les données manquantes. Cependant, il faut être très prudent avant d'introduire des attributs annulables.

Références

[Codd1970a]

Edgard F. CODD ;

A Relational Model of Data for Large Shared Data Banks ;

Communications of the ACM, 13(6), pp. 377–387, 1970 ;

doi:10.1145/362384.362685.

[Codd1990a]

Edgard F. CODD ;

The Relational Model for Database Management: Version 2 ;

Addison-Wesley Longman Publishing, Boston (MA, USA), 1990 ;

ISBN 0-201-14192-2.

[Date1998a]

Chris J. DATE, Hugh DARWEN;

First Edition : *Foundation for Object/Relational Database Systems: The Third Manifesto* ;
Addison-Wesley Redwood City (CA, US), 1998 ; ISBN 0-201-30978-5.

Second Edition : *Foundation for Future Database Systems: The Third Manifesto* ;
Addison-Wesley, Redwood City (CA, US), 2000 ; ISBN 0-201-70928-7.

Third edition : *Databases, types, and the relational model: The third manifesto* ;
Addison-Wesley (Pearson Education), 2007 ; ISBN 0-321-39942-0.

Third revised edition : *Databases, types, and the relational model: The third manifesto* ;
2014, <https://www.dcs.warwick.ac.uk/~hugh/TTM/DTATRM.pdf> (consulté le 2024-05-30).

[Date2015a]

Chris J. DATE;

SQL and relational theory: how to write accurate SQL code ;
O'Reilly Media, 2015 ;
ISBN 978-1-4919-4117-1.

[Date2020a]

Chris J. DATE;

Logic and Relational Theory;

Technics Publications, Basking Ridge (NJ, US), 2020;

ISBN 978-1634628754.

[Russell1908a]

Bertrand RUSSELL;

Mathematical Logic as Based on the Theory of Types;

American Journal of Mathematics, vol. 30, no 3, 1908, p. 222–262;

ISSN 0002-9327, DOI 10.2307/2369948.

Produit le 2026-04-07 15:55:23 UTC



Université de Sherbrooke